

پروژه پایانی درس یادگیری تقویتی

طراحی و تحلیل عامل هوشمند در هزارتوی پویا

نام دانشجو: امیرمحمد جمالدار

شماره دانشجویی: 40400356

اختصاصی: 5 | اندازه نقشه: 16×16 Seed

تاریخ تهیه گزارش: ژوئیه 2026

چکیده

در این پروژه یک محیط هزارتوی پویای 16×16 با انتقال تصادفی، کلید، در قفل، هدف، خانه‌های جریمه و یک دروازه دوره‌ای طراحی شد. حالت عامل به صورت (ردیف، ستون، وضعیت کلید، فاز دروازه) تعریف شد تا خاصیت مارکوف حفظ شود. سه الگوریتم Value Iteration، Q-Learning و $SARSA(\lambda)$ بدون استفاده از کتابخانه‌های آماده یادگیری تقویتی پیاده‌سازی شدند. آزمایش‌های اصلی روی Seed 5 مستقل و داده‌های اپیزودی خام انجام شد. بهترین برنامه کاهش اکتشاف در داده‌های این اجرا «exponential» و بهترین مقدار λ برابر 0.7 بود. توافق دقیق سیاست حریصانه Q-Learning و $SARSA(\lambda)$ با سیاست مرجع Value Iteration به ترتیب 49.6 و 52.2 درصد به دست آمد. انتقال یادگیری در دو مقصد با تغییر محدود و گسترده بررسی و یک نمونه انتقال منفی با regret عددی مستند شد. تمام نمودارها از CSVهای خام مخزن تولید شده‌اند.

کلیدواژه‌ها: یادگیری تقویتی، فرایند تصمیم‌گیری مارکوف، Value Iteration، $SARSA(\lambda)$ ، Q-Learning، انتقال یادگیری، Reward Shaping، Eligibility Trace.

فهرست مطالب


1. تعریف مسئله و محیط اختصاصی
2. مدل‌سازی کامل MDP
3. طراحی تابع پاداش
4. پیاده‌سازی الگوریتم‌ها
5. پروتکل آزمایش و معیارهای آماری
6. نتایج Value Iteration
7. نتایج Q-Learning و طراحی پاداش
8. نتایج $SARSA(\lambda)$
9. مقایسه سه الگوریتم و اختلاف سیاست
10. انتقال یادگیری
11. رابط گرافیکی و بازتولیدپذیری
12. پاسخ مستقیم به پرسش‌های تحلیلی

13. محدودیت‌ها و جمع‌بندی

پیوست‌ها و منابع

1. تعریف مسئله و محیط اختصاصی

مطابق قاعده پروژه، رقم یکی مانده به آخر شماره دانشجویی 40400356 برابر 5 است؛ بنابراین اندازه نقشه از رابطه $5 + 15 \pmod{4}$ برابر 16 شد. نقشه نهایی شامل 109 خانه دیوار با نسبت 42.6 درصد و 5 خانه جریمه است. مسیر شروع به کلید و سپس کلید به هدف با BFS قطعی اعتبارسنجی و فایل JSON نقشه برای اجرای یکسان تمام الگوریتمها ثابت شد.




شکل 1 - نقشه مبدأ اختصاصی تولیدشده با Seed برابر 5

مانع عمودی میانی، عبور بدون کلید را از در D غیرممکن می کند. پس از دریافت K، عامل وارد نیمه راست می شود. دروازه G در مسیر کوتاه قرار دارد و تنها در فازهای 0 و 1 باز است؛ مسیر دورتر نیز وجود دارد. بنابراین قابلیت پویا صرفاً نمایشی نیست و تصمیم انتظار، عبور یا انتخاب مسیر جایگزین را تغییر می دهد.

مقدار	مولفه
[2, 14]	نقطه شروع


محل کلید	[4,11]
محل هدف	[13,3]
تعداد خانه قابل عبور	147
سقف گام	441
دوره دروازه	4
فازهای باز	1 و 0

در مقصد مشابه، 6 مانع داخلی حذف و همین تعداد مانع در محل جدید اضافه شد؛ نسبت جابه‌جایی نسبت به موانع داخلی مبدأ 12.2 درصد است. در مقصد متفاوت، این مقادیر 13 و 26.5 درصد هستند و علاوه بر آن محل کلید/هدف و تعداد خانه‌های جریمه تغییر کرده است.



شکل 2 - محیط مقصد مشابه

شروع، کلید و هدف ثابت مانده‌اند و تغییرات محدود عمدتاً در همسایگی‌های محلی رخ داده است. این ساختار باید برای انتقال انتخابی مناسب‌تر باشد، زیرا بخش بزرگی از روابط عمل-نتیجه مبدأ هنوز معتبر است.



شکل 3 - محیط مقصد متفاوت

تغییر گسترده دیوارها، جابه‌جایی عناصر مأموریت و افزایش خانه‌های جریمه باعث می‌شود کپی بی‌قید و شرط جدول Q، عمل‌هایی را ترجیح دهد که در مقصد دیگر مناسب نیستند؛ این محیط برای آشکارکردن انتقال منفی طراحی شده است.

2. مدل‌سازی کامل MDP

2-1. فضای حالت و خاصیت مارکوف

$$S = \{(r, c, k, p) \mid (r, c) \text{ is passable, } k \in \{0, 1\}, p \in \{0, 1, 2, 3\}\}$$

متغیرهای r و c مختصات عامل، k وضعیت دریافت کلید و p فاز دروازه دوره‌ای هستند. مختصات به‌تنهایی کافی نیست؛ زیرا قابلیت عبور از در D به k و قابلیت عبور از G به p وابسته است. با دانستن همین چهار مولفه و عمل انتخابی، توزیع حالت بعد، پاداش و پایان مأموریت مشخص می‌شود و نیازی به تاریخچه نیست.

2-2. فضای عمل و تابع انتقال

$$A = \{UP, DOWN, LEFT, RIGHT\}$$

$$P(\text{realized}=a \mid \text{selected}=a)=0.8, \quad P(\text{each perpendicular action})=0.1$$

در هر انتقال، فاز زمانی یک واحد جلو می‌رود؛ حتی اگر عامل به علت دیوار، در قفل یا دروازه بسته در مکان خود بماند. این نکته برای یادگیری زمان‌بندی عبور حیاتی است. ورود به کلید k را از صفر به یک تغییر می‌دهد. هدف پس از دریافت کلید حالت پایانی است.

2-3. پایان و truncation

رسیدن به هدف termination واقعی MDP است. سقف گام، یک محدودیت آزمایش از نوع TimeLimit است و با truncated ثبت می‌شود. واردکردن شمارنده گام در حالت MDP را افق محدود و فضای حالت را چندصد برابر می‌کند و با Value Iteration ایستای مورد انتظار پروژه ناسازگار بود؛ بنابراین این محدودیت خارج از هسته MDP و یکسان برای همه روش‌ها اعمال شد.

2-4. سیاست

$$pi(a|s) = \text{probability of selecting action } a \text{ in state } s$$

سیاست Value Iteration پس از همگرایی حریصانه است. در Q-Learning و SARSA(λ)، سیاست رفتار ϵ -greedy است و ϵ طی آموزش کاهش می‌یابد؛ در ارزیابی، عمل حریصانه با شکستن tie به صورت قطعی انتخاب می‌شود.

3. طراحی تابع پاداش

پاداش پایه	رویداد
-0.5	هر گام
-1.5 افزوده	برخورد با دیوار/دروازه بسته
-7 افزوده	ورود به خانه جریمه
+25 افزوده	دریافت کلید
-4 افزوده	تلاش برای در قفل
+120 افزوده	رسیدن به هدف

در نسخه sparse همین مقادیر استفاده شدند. هزینه گام از سرگردانی جلوگیری می‌کند و پاداش هدف به قدری بزرگ است که مسیرهای معقول حتی با چند انحراف تصادفی بازده مثبت داشته باشند. برای عبور موفق از در پاداش جداگانه داده نشد، زیرا عبور رفت و برگشتی می‌توانست به جمع‌آوری پاداش فرعی تبدیل شود.

$$r_shaped = r_sparse + \eta [\gamma \Phi(s') - \Phi(s)], \quad \eta = 0.2$$

پتانسیل پیش از کلید برابر منفی فاصله باقی‌مانده تا کلید به علاوه فاصله کلید تا هدف، و پس از کلید برابر منفی فاصله تا هدف است. این ساختار اطلاعات میانی می‌دهد و در حالت ایده‌آل سیاست بهینه MDP تنزیل شده را حفظ می‌کند. مقیاس اولیه 1.0 در stress-test بازخورد مثبت بزرگی برای ماندن در فاصله زیاد ایجاد کرد؛ نسخه نهایی با $\eta=0.2$ و هزینه گام -0.5 این رفتار را حذف کرد. این یکی از دو پیشنهاد ناقص مستند شده در بخش شفافیت ابزارهاست.

4. پیاده‌سازی الگوریتم‌ها

4-1 Value Iteration

$$V_{k+1}(s) = \max_a \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma V_k(s')]$$

مدل انتقال دقیق از تابع transition_outcomes محیط استخراج و backup بلمن به صورت برداری اجرا شد. بردار سازی فقط بهینه‌سازی محاسباتی است و هیچ پیاده‌سازی آماده برنامه‌ریزی یا RL استفاده نشده است. شرط همگرایی، بیشینه قدرمطلق تغییر V در دو تکرار متوالی کمتر از 10^{-8} است.

4-2 Q-Learning

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

Q-Learning off-policy است؛ هدف به روزرسانی عمل حریصانه حالت بعد را فرض می‌کند، اما داده ممکن است با عمل اکتشافی تولید شده باشد. دو برنامه کاهش خطی و نمایی ϵ با نقاط شروع و پایان یکسان مقایسه شدند.

4-3 SARSA(lambda)

$$\begin{aligned} \Delta_t &= r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \\ E_t(s,a) &= \gamma \lambda E_{t-1}(s,a); \quad E_t(s_t, a_t) = 1 \quad (\text{replacing trace}) \\ Q &\leftarrow Q + \alpha \Delta_t E \end{aligned}$$

ردپای replacing انتخاب شد، زیرا در محیطی با حلقه، برخورد و ماندن، accumulating trace می‌تواند بازدید مکرر یک زوج حالت-عمل را بیش از حد تقویت کند. $\lambda=0$ به SARSA یک مرحله‌ای تبدیل می‌شود و افزایش λ خطای TD را به تعداد بیشتری از زوج‌های قبلی منتقل می‌کند.

5. پروتکل آزمایش و معیارهای آماری


آزمایش submission با 1200 اپیزود برای هر اجرای اصلی و Seedهای [5, 15, 25, 35, 45] انجام شد. انتقال یادگیری با 800 اپیزود و Seedهای [5, 25, 45] اجرا شد. ارزیابی نهایی هر سیاست شامل 250 اپیزود با انتقال تصادفی محیط بود. میانگین، انحراف معیار و نوار اطمینان 95 درصد منحنی‌ها از تمام Seedها محاسبه شدند.

معیارها شامل بازده اپیزود، تعداد گام، نرخ موفقیت، برخورد با دیوار، ورود به خانه جریمه، زمان اجرا، حافظه جدول‌ها، توافق سیاست با Value Iteration، عملکرد اولیه انتقال، مساحت زیر منحنی موفقیت اولیه، اپیزود رسیدن به موفقیت 80 درصد و عملکرد نهایی است. گزارش فقط بهترین Seed را نمایش نمی‌دهد.

6. نتایج Value Iteration


γ	تکرار	همگرا	delta نهایی	زمان (s) backup	γ شروع
0.85	126	True	9.31e-09	0.0221	10.050
0.95	354	True	9.99e-09	0.0578	35.039
0.99	1874	True	9.94e-09	0.3095	92.410

با افزایش γ از 0.85 به 0.99 تعداد تکرار از 126 به 1874 افزایش یافت. دلیل آن کاهش نرخ contraction عملکرد بلمن در γ های نزدیک یک است. در مقابل، مقدار شروع و حساسیت سیاست به پیامدهای دوردست افزایش می‌یابد. $\gamma=0.95$ تعادل مناسبی میان افق تصمیم‌گیری مأموریت چندمرحله‌ای و هزینه همگرایی ایجاد کرد.




شکل 4 - Heatmap ارزش بهینه پیش از دریافت کلید

شیب ارزش عامل را ابتدا به سمت K هدایت می‌کند و نواحی بن‌بست/پرخطر ارزش پایین‌تری دارند. ارزش فقط تابع مکان نیست؛ این شکل برش $k=0$ و فاز صفر است و برش پس از کلید متفاوت خواهد بود.




شکل 5 - Heatmap ارزش بهینه پس از دریافت کلید

پس از تغییر k به یک، هدف واسط حذف می‌شود و ساختار ارزش به سمت در، دروازه و هدف نهایی می‌چرخد. تفاوت دو Heatmap نشان می‌دهد افزودن متغیر کلید به حالت یک ضرورت مدل‌سازی است، نه جزئیات پیاده‌سازی.



شکل 6 - سیاست بهینه Value Iteration پیش از کلید

فلش‌ها بهترین عمل را برای فاز صفر نشان می‌دهند. نزدیک دیوارها ممکن است عمل ظاهراً غیرمستقیم انتخاب شود، چون 20 درصد احتمال انحراف و هزینه برخورد در امیدریاضی تصمیم وارد شده است.




شکل 7 - سیاست بهینه Value Iteration پس از کلید

در بخش راست نقشه، سیاست زمان‌بندی عبور از G و مسیر جایگزین را با توجه به فاز دروازه می‌آموزد. نمایش یک فاز به‌تنهایی تمام سیاست را نشان نمی‌دهد، اما ساختار مکانی تصمیم را روشن می‌کند.


7. نتایج Q-Learning و طراحی یاداش

برنامه ϵ	موفقیت نهایی	بازده نهایی	گام نهایی	میانۀ ایزود تا 80%
exponential	0.999	116.85	39.4	397
linear	1.000	119.18	36.2	470



شکل 8 - مقایسه نرخ موفقیت برنامه‌های کاهش ϵ


بر اساس میانگین Seedها، برنامه «exponential» انتخاب شد. معیار انتخاب فقط بازده یک اجرا نبود؛ موفقیت نهایی و سرعت عبور از آستانه 80 درصد با هم بررسی شدند. اختلاف نوارهای اطمینان در ابتدای آموزش نشان می‌دهد زمان‌بندی اکتشاف روی کشف زنجیره کلید-در-هدف اثر مستقیم دارد.



شکل 9 - مقایسه بازده برنامه‌های کاهش ϵ


بازده در مراحل اولیه نوسان زیادی دارد، زیرا سیاست اکتشافی هم با دیوارها برخورد می‌کند و هم ممکن است پس از گرفتن کلید نتواند مأموریت را تمام کند. پس از کاهش ϵ ، پراکندگی کم و بازده به محدوده پایدار نزدیک می‌شود.

پاداش	موفقیت نهایی	بازده نهایی	گام نهایی	میانۀ ایزود تا 80%
shaping	0.999	116.85	39.4	397
sparse	1.000	106.99	39.4	463



شکل 10 - نرخ موفقیت **shaping** و **sparse**

پاداش شکل‌دهی شده سرعت یادگیری را از نظر میانۀ رسیدن به آستانه 80 درصد از 463 به 397 ایزود تغییر داد. مقایسه موفقیت نهایی (1.000 در برابر 0.999) مشخص می‌کند اثر **shaping** فقط شتاب اولیه بوده یا در بودجه محدود آموزش روی کیفیت نهایی نیز اثر گذاشته است.




شکل 11 - بازده sparse و shaping

مقادیر مطلق بازده دو تعریف مستقیماً هم‌مقیاس نیستند، زیرا shaping جمله پتانسیل را اضافه می‌کند. بنابراین این نمودار باید همراه نرخ موفقیت، طول مسیر و توافق سیاست تفسیر شود؛ استفاده از بازده به‌تنهایی می‌توانست نتیجه‌گیری غلط ایجاد کند.



شکل 12 - Heatmap تعداد بازدید Q-Learning

تراکم بازدید در مسیرهای نزدیک شروع و نقاط تصمیم بیشتر است. نواحی کم بازدید همان جاهایی هستند که Q-Learning احتمالاً با سیاست مرجع اختلاف بیشتری دارد؛ زیرا برآورد Q در آن‌ها داده کافی دریافت نکرده است.



شکل 13 - یک مسیر نهایی عامل Q-Learning

مسیر نمایش داده شده یک rollout واقعی با تصادفی بودن انتقال است، نه مسیر دست ساز. انحرافهای محدود نسبت به مسیر هندسی کوتاه ناشی از لغزش $0.1+0.1$ و واکنش سیاست به فاز دروازه هستند.

7-1. بازسازی یک Q-update واقعی

مقدار	مولفه
1 / 0	اپیزود/گام
(0 , 0 , 2 , 14)	حالت
3	عمل
0.0900-	پاداش
(1 , 0 , 3 , 14)	حالت بعد
0.000000	Q قبل
0.000000	max Q بعد


هدف TD	0.090000-
خطای TD	0.090000-
Q بعد	0.019800-

$$Q_{\text{new}} = 0.000000 + 0.22 * (-0.090000 - 0.000000) = -0.019800$$

اعداد جدول مستقیماً از فایل q_learning_manual_update_trace.csv خوانده شده‌اند. بنابراین این محاسبه یک مثال فرضی نیست و می‌توان آن را با همان Seed بازتولید کرد.


8. نتایج SARSA(lambda)

λ	موفقیت	بازده	گام	اییزود تا 80%	برخورد	خطر
lambda=0.0	0.780	35.8	165.1	801	17.29	1.30
lambda=0.3	0.919	86.4	88.0	738	9.24	1.46
lambda=0.7	0.927	100.0	71.1	665	5.23	1.17
lambda=0.9	0.006	107.1-	438.7	دستیابی نشد	5.08	0.29



شکل 14 - نرخ موفقیت برای چهار مقدار λ

بهترین تعادل داده‌های این پروژه در $\lambda=0.7$ مشاهده شد. λ صفر فقط اعتبار یک گام را منتشر می‌کند و معمولاً کندتر است؛ λ بسیار بزرگ خطاهای noisy ناشی از انتقال تصادفی و سیاست اکتشافی را به دنباله طولانی‌تری پخش می‌کند و می‌تواند ناپایداری را افزایش دهد.



شکل 15 - بازده برای چهار مقدار λ

بهبود سرعت در λ میانی ناشی از credit assignment چندمرحله‌ای است. افت یا نوسان $\lambda=0.9$ نشان می‌دهد بزرگ‌کردن trace همیشه بهتر نیست؛ به‌ویژه وقتی اپیزودها شامل برخورد، لغزش و حلقه باشند.

8-1. ثبت delta و Eligibility Trace

ردپای فعال بعد	ردپای فعال قبل	delta	پاداش	عمل	حالت	گام
1	1	0.09000-	0.090-	3	(0,0,2,14)	1
2	2	0.48000-	0.480-	2	(1,0,3,14)	2
3	3	1.78000-	1.780-	1	(2,0,2,14)	3
4	4	0.47000-	0.470-	2	(3,0,2,14)	4
5	5	1.77000-	1.770-	1	(0,0,1,14)	5
6	6	0.08000-	0.080-	0	(1,0,1,14)	6

در هر گام، زوج فعلی در replacing trace مقدار یک می‌گیرد و سپس تمام ردپاها با $\gamma\lambda$ کاهش می‌یابند. علامت delta تعیین می‌کند مقادیر Q زوج‌های اخیر هم‌جهت یا خلاف جهت تغییر کنند. با $\lambda=0$ این حافظه بلافاصله صفر می‌شود و الگوریتم به SARSA یک‌مرحله‌ای نزدیک می‌گردد.

9. مقایسه سه الگوریتم و اختلاف سیاست


توافق سیاست	حافظه (byte)	زمان (s)	گام	بازده	موفقیت	روش
± 0.538 0.026	0 ± 65536	± 2.912 0.389	2.2 ± 36.7	± 119.52 1.63	± 0.999 0.002	Q-Learning
± 0.523 0.006	0 ± 65536	± 7.821 1.270	47.6 ± 70.5	± 101.92 27.36	± 0.926 0.119	SARSA(lambd a)
1.000	83968	0.058	31.4	122.86	1.000	Value Iteration

Value Iteration به نمونه تعاملی نیاز ندارد، اما مدل کامل انتقال و حافظه V/Q را لازم دارد. Q-Learning و SARSA(λ) مدل آزادند و هزینه اصلی آن‌ها تعداد گام‌های تجربه است. زمان‌های جدول شامل آموزش هر اجرا هستند؛ برای Value Iteration زمان backup بلمن گزارش شده است. حافظه SARSA هنگام آموزش علاوه بر Q شامل Eligibility Trace فعال است، هرچند مدل ذخیره‌شده نهایی فقط Q را نگه می‌دارد.



شکل 16 - اختلاف سیاست Q-Learning با مرجع

نرخ توافق دقیق روی حالت‌های قابل‌دسترسی 49.6 درصد است. این معیار سخت‌گیرانه است: اگر دو عمل ارزش تقریباً برابر داشته باشند ولی argmax متفاوت شود، اختلاف ثبت می‌شود. با این حال نقشه نشان می‌دهد اختلاف‌ها در نواحی کم‌نمونه، کنار خطر و نزدیک تصمیم‌های فازی متمرکزند.



شکل 17 - اختلاف سیاست $SARSA(\lambda)$ با مرجع

توافق $SARSA(\lambda)$ برابر 52.2 درصد است. $on-policy$ بودن می‌تواند نزدیک خطر، سیاست محتاط‌تری بسازد چون ارزش عمل بعدی همان سیاست ϵ -greedy را در نظر می‌گیرد، نه عمل حریصانه فرضی.

9-1. سه حالت نمونه اختلاف

حالت	خانه	عمل مدل آزاد	عمل VI	Q مدل آزاد	Q مرجع
[0,0,1,1]	.	0	3	,0.0,0.0,0.0] [0.0	,13.672] ,15.642 ,13.643 [15.843
[1,0,1,1]	.	0	3	,0.0,0.0,0.0] [0.0	,13.669] ,13.64,15.647 [15.849

[2,0,1,1]	.	0	3	,0.0,0.0,0.0] [0.0	,13.668] ,15.644 ,13.639 [15.845
-----------	---	---	---	-----------------------	---

علت مشترک این اختلاف‌ها سه چیز است: پوشش نمونه محدود در ترکیب‌های خاص k و p ، نویز bootstrap و tie‌های نزدیک، و تفاوت میان هدف بهینه‌سازی سیاست رفتار با سیاست کاملاً حریصانه. در حالت‌های کنار دیوار یا خطر، یک انحراف عمود می‌تواند رتبه اعمال را عوض کند؛ در نزدیکی G نیز فاز زمانی به اندازه مکان اهمیت دارد.

10. انتقال یادگیری

10-1. مقصد مشابه

سناریو	موفقیت اولیه	AUC اولیه	اپیزود تا 80%	موفقیت نهایی	بازده نهایی	گام نهایی	سهم کپی
full	0.096	0.755	118	1.000	113.1	33.9	1.000
scaled_beta_0.25	0.096	0.593	204	1.000	112.1	34.9	1.000
scaled_beta_0.50	0.096	0.746	121	1.000	115.5	33.3	1.000
scaled_beta_0.75	0.096	0.768	116	1.000	114.5	33.5	1.000
scratch	0.000	0.172	دستیابی نشد	0.000	115.0-	441.0	0.000
selective	0.000	0.440	205	1.000	116.0	35.9	0.617

در مقصد مشابه، سناریوی scaled_beta_0.75 بیشترین AUC موفقیت اولیه را داشت. خط مبنای آموزش از صفر $AUC=0.172$ و موفقیت اولیه $=0.000$ داشت، در حالی که سناریوی منتخب به ترتیب 0.768 و 0.096 ثبت کرد. عملکرد نهایی جداگانه گزارش شده است؛ برتری آغازین لزوماً تضمین‌کننده بهترین انتهای آموزش نیست.


یک نکته مهم این است که همه انتقال‌های تعدیل‌شده در لحظه آغاز موفقیت یکسانی دارند. دلیل، خطا یا بی‌اثر بودن β نیست: ضرب تمام Q ها در هر β مثبت، ترتیب اعمال و argmax را عوض نمی‌کند. اثر β پس از شروع یادگیری ظاهر می‌شود، زیرا قدرمطلق مقادیر اولیه اندازه خطای TD و سرعت کنارگذاشتن دانش ناسازگار را تغییر می‌دهد.

10-2. مقصد متفاوت

سناریو	موفقیت اولیه	AUC اولیه	ایپزود تا 80%	موفقیت نهایی	بازده نهایی	گام نهایی	سهم کپی
full	0.152	0.227	247	1.000	113.0	61.9	1.000
scaled_beta_0.25	0.152	0.460	184	1.000	116.2	59.4	1.000
scaled_beta_0.50	0.152	0.377	211	1.000	114.2	60.9	1.000
scaled_beta_0.75	0.152	0.305	228	1.000	114.5	61.3	1.000
scratch	0.000	0.234	366	1.000	114.1	64.0	0.000
selective	0.000	0.206	241	1.000	114.6	61.5	0.321


در مقصد متفاوت، سناریوی scaled_beta_0.25 بیشترین AUC موفقیت اولیه را داشت. خط مبنای آموزش از صفر $AUC=0.234$ و موفقیت اولیه $=0.000$ داشت، در حالی که سناریوی منتخب به ترتیب 0.460 و 0.152 ثبت کرد. عملکرد نهایی جداگانه گزارش شده است؛ برتری آغازین لزوماً تضمین کننده بهترین انتهای آموزش نیست.

یک نکته مهم این است که همه انتقال های تعدیل شده در لحظه آغاز موفقیت یکسانی دارند. دلیل، خطا یا بی اثر بودن β نیست: ضرب تمام Q ها در هر β مثبت، ترتیب اعمال و argmax را عوض نمی کند. اثر β پس از شروع یادگیری ظاهر می شود، زیرا قدرمطلق مقادیر اولیه اندازه خطای TD و سرعت کنار گذاشتن دانش ناسازگار را تغییر می دهد.



شکل 18 - انتقال به مقصد مشابه

در محیط مشابه، انتقال کامل یا انتخابی معمولاً باید شروع بهتری از scratch داشته باشد، چون ساختار محلی بسیاری از حالت‌ها ثابت مانده است. تفاوت سناریوهای β نشان می‌دهد کاهش شدت انتقال می‌تواند میان استفاده از دانش و امکان اصلاح تعادل ایجاد کند.



شکل 19 - انتقال به مقصد متفاوت

در محیط متفاوت، کپی کامل می‌تواند عملکرد اولیه را بدتر کند یا سرعت اصلاح را کاهش دهد. انتقال انتخابی و β های کوچکتر دانش نامعتبر را محدود می‌کنند، هرچند ممکن است بخشی از دانش مفید را نیز کنار بگذارند.

10-3. نمونه انتقال منفی

مقدار	مولفه
[2, 1, 12, 3]	حالت
P	خانه
2	عمل منتقل شده
3	عمل بهینه مقصد
17.695803	regret
[85.1405, 93.7558, 80.4999, 60.2599]	Q منتقل شده
[107.6236, 89.9278, 99.8907, 99.8907]	Q بهینه مقصد


در این حالت، جدول مبدأ عملی را ترجیح می‌دهد که به ساختار قبلی وابسته بوده است. در مقصد، تغییر دیوار/خطر/موقعیت مأموریت باعث می‌شود ارزش بهینه عمل دیگری بیشتر باشد. regret اختلاف ارزش بهینه مقصد بین عمل درست و عمل القاشده از مبدأ است؛ بنابراین انتقال منفی با معیار عددی تعریف شده، نه با عبارت مبهم «انتقال بد بود».

مقادیر این حالت در ابتدای انتقال و پس از آموزش مقصد به صورت زیر ثبت شدند:

$$Q_{\text{before}} = [60.2599, 80.4999, 93.7558, 85.1405]$$

$$Q_{\text{after}} = [94.4624, 87.8161, 74.1505, 110.1551]$$

تغییر ترتیب مقادیر نشان می‌دهد تجربه مقصد چگونه ترجیح اولیه نامناسب را تصحیح کرده است.



شکل 20 - میزان اصلاح Q پس از انتقال کامل

بیشترین تغییر Q در همسایگی‌هایی رخ می‌دهد که ساختار مقصد با مبدأ ناسازگار است یا سیاست اولیه مرتباً آن‌ها را تجربه می‌کند. تغییر کم الزاماً به معنای انتقال صحیح نیست؛ حالت کم‌بازدید ممکن است فرصت اصلاح پیدا نکرده باشد.

11. رابط گرافیکی و بازتولیدپذیری

رابط Tkinter در `gui/app.py` مستقل از نمودارهای ثابت است و حرکت عامل را مرحله‌به‌مرحله نمایش می‌دهد. دیوار، کلید، در، هدف، خطر، دروازه باز/بسته و عامل نشانه بصری متمایز دارند. انتخاب الگوریتم و محیط، آموزش/ارزیابی، شروع، توقف، ادامه، بازنشانی، اجرای مجدد، سرعت انیمیشن و نمایش سیاست در رابط تعبیه شده است. اطلاعات زنده شامل اپیزود، گام، بازده، ϵ ، وضعیت کلید، موفقیت اخیر و وضعیت دروازه است.

```
python main.py
python experiments/run_experiments.py --profile submission
pytest -q
```

تمام مسیرها نسبی و مبتنی بر ریشه مخزن هستند. run_manifest.json نسخه Python, NumPy, Pandas سیستم عامل، Seed ها و بودجه اپیزود را ثبت می کند. مدل ها با NPZ فشرده و داده های خام با CSV/JSONL ذخیره شده اند. تاریخچه Git شامل مراحل محیط، الگوریتم ها، آزمایش ها/GUI و نتایج/گزارش است.

12. پاسخ مستقیم به پرسش های تحلیلی

12-1. تعریف MDP و حفظ خاصیت مارکوف

MDP به صورت پنج تایی (S, A, P, R, γ) تعریف شد. S شامل مکان، کلید و فاز دروازه؛ A شامل چهار حرکت؛ P شامل احتمال $0.8/0.1/0.1$ و منطق برخورد؛ R یکی از دو نسخه پاداش؛ و $\gamma=0.95$ است. هدف پس از کلید terminal است. حذف k پیش بینی عبور از در و حذف p پیش بینی عبور از دروازه را به تاریخچه وابسته می کرد؛ پس هر دو برای مارکوف بودن لازم اند.

12-2. on-policy و off-policy نزدیک خطر

Q-Learning هدف max Q را استفاده می کند و فرض می کند در آینده عمل حریصانه اجرا خواهد شد؛ SARSA ارزش عمل واقعی ϵ -greedy را وارد می کند. در ارزیابی این پروژه، میانگین ورود به خطر برای Q-Learning برابر 1.336 و برای SARSA برابر 1.121 بود؛ برخورد با دیوار نیز 4.048 در برابر 4.388 ثبت شد. تفاوت باید همراه طول مسیر تفسیر شود: سیاست محتاط تر ممکن است امن تر ولی طولانی تر باشد.

12-3. نیاز Value Iteration به مدل

Value Iteration برای محاسبه امید ریاضی backup بلمن باید تمام حالت های بعد، احتمال و پاداش آن ها را بداند. مزیت آن سیاست مرجع بدون خطای نمونه و همگرایی قابل کنترل است؛ محدودیت آن نیاز به مدل و رشد هزینه با فضای حالت است. Q-Learning و SARSA فقط نمونه (s,a,r,s) می خواهند و برای محیط ناشناخته مناسب ترند، اما به اپیزودهای زیاد، اکتشاف و تنظیم پارامتر حساس اند.

12-4. بهترین λ

$\lambda=0.7$ بهترین تعادل را ایجاد کرد: موفقیت نهایی میانگین 0.927، بازده 99.95 و میانه زمان رسیدن به 80 درصد 665 اپیزود بود. λ های بزرگ تر حافظه اعتباری طولانی تری داشتند، اما نویز انتقال و اکتشاف را نیز به گذشته پخش کردند.

12-5. سه اختلاف سیاست

سه حالت جدول بخش 9-1 از فایل مقایسه واقعی استخراج شدند. تحلیل محلی نشان داد اختلاف‌ها به دیوار/خطر مجاور، فاز دروازه و کمبود بازدید وابسته‌اند. علاوه بر این، معیار argmax به tie‌های نزدیک حساس است؛ پس درصد توافق باید در کنار regret یا اختلاف مقدار Q خوانده شود.

12-6. محیط مشابه و متفاوت در انتقال

انتقال کامل در مقصد مشابه موفقیت اولیه 0.096 و AUC اولیه 0.755 داشت؛ همین مقادیر در مقصد متفاوت 0.152 و 0.227 شدند. این اعداد نشان می‌دهند شباهت ساختاری به‌تنهایی ترتیب عملکرد اولیه را تعیین نمی‌کند؛ هندسه مسیر، محل خطر و قابلیت اکتشاف نیز مؤثرند. شاهد روشن آن است که scratch در مقصد مشابه با موفقیت نهایی 0.000 در بودجه 800 اپیزود شکست خورد، اما در مقصد متفاوت به 1.000 رسید. بنابراین «مشابه‌تر» الزاماً «آسان‌تر» نیست. در عین حال، انتقال در مقصد مشابه سرعت یادگیری بسیار بیشتری از scratch ایجاد کرد و در مقصد متفاوت $\beta=0.25$ سریع‌تر از کپی کامل دانش ناسازگار را اصلاح کرد.

13. محدودیت‌ها و جمع‌بندی

نخست، محیط جدولی است و تعمیم تابعی به نقشه‌های بسیار بزرگ بررسی نشده است. دوم، برش‌های دوبعدی سیاست فقط یک وضعیت کلید و فاز را نشان می‌دهند، در حالی که سیاست کامل چهاربعدی است. سوم، پنج Seed برای آزمایش اصلی و سه Seed برای انتقال عدم قطعیت را کاهش می‌دهد ولی جای تحلیل بسیار بزرگ را نمی‌گیرد. چهارم، معیار توافق دقیق به tie حساس است. پنجم، TimeLimit خارج از MDP ایستا اعمال شده و اگر هدف تحلیل افق محدود باشد باید شمارنده زمان به حالت افزوده و برنامه‌ریزی پسرو استفاده شود.

نتیجه اصلی این است که کیفیت پروژه فقط با بازده نهایی سنجیده نمی‌شود. مدل درست حالت، پاداش بدون loop-hole، برنامه اکتشاف، طول trace و میزان شباهت مبدأ/مقصد همگی رفتار عامل را تغییر می‌دهند. Value Iteration مرجع ساختاری فراهم کرد؛ Q-Learning سیاست off-policy کارآمدی آموخت؛ $\text{SARSA}(\lambda)$ اثر credit assignment و احتیاط on-policy را نشان داد؛ و انتقال انتخابی/تعدیل شده در برابر انتقال منفی مقاوم‌تر بود.

پیوست الف - شفافیت استفاده از ابزارهای کمکی

مورد	پیشنهاد	اصلاح/اعتبارسنجی	دلیل
حالت	مختصات و کلید	افزودن فاز دروازه	حفظ خاصیت مارکوف

Reward shaping	پاداش فاصله مستقیم	پتانسیل محور با $\eta=0.2$	جلوگیری از تغییر سیاست و حلقه
Eligibility trace	accumulating	replacing و آزمایش چهار λ	کنترل تقویت بازدید تکراری
پیشنهاد ناقص 1	shaping با مقیاس 1.0	کاهش مقیاس و افزایش هزینه گام	حذف بازده حلقه‌ای نامطلوب
پیشنهاد ناقص 2	مسیر پایه حدود 40 گام	بازطراحی مسیر به مأموریت کوتاه‌تر	قابل اکتشاف شدن با بودجه اپیزود
بهینه‌سازی	حلقه Python برای VI	backup برداری از مدل مستقل	کاهش زمان بدون تغییر معادله

هیچ خروجی پیشنهادشده بدون اجرا و بررسی وارد نسخه نهایی نشد. دو مورد ناسازگار بالا با مشاهده داده واقعی شناسایی و اصلاح شدند. کد نهایی با تست واحد و اجرای چند Seed اعتبارسنجی شده است.

پیوست ب - ساختار تحویل و بازتولید

RL_FinalProject_40400356/

environments/ agents/ transfer/ gui/ experiments/ results/ tests/
report.pdf requirements.txt README.md main.py

فایل‌های تنظیمات هر دسته آزمایش در experiments/configs، داده خام در results/raw_data، مدل‌ها در results/models و تصاویر در results/figures قرار دارند. required_event_examples.jsonl نمونه همه رویدادهای اجباری را ثبت می‌کند.

منابع

- [1] Sutton, R. S., & Barto, A. G. Reinforcement Learning: An Introduction, 2nd ed., MIT Press, 2018.
- [2] Bellman, R. Dynamic Programming. Princeton University Press, 1957.
- [3] Watkins, C. J. C. H., & Dayan, P. Q-learning. Machine Learning, 8, 279-292, 1992.
- [4] Rummery, G. A., & Niranjan, M. On-line Q-learning using connectionist systems. Cambridge University Engineering Department, 1994.
- [5] Ng, A. Y., Harada, D., & Russell, S. Policy invariance under reward transformations. ICML, 1999.